

Distribuições de Probabilidades e Testes de Hipótese

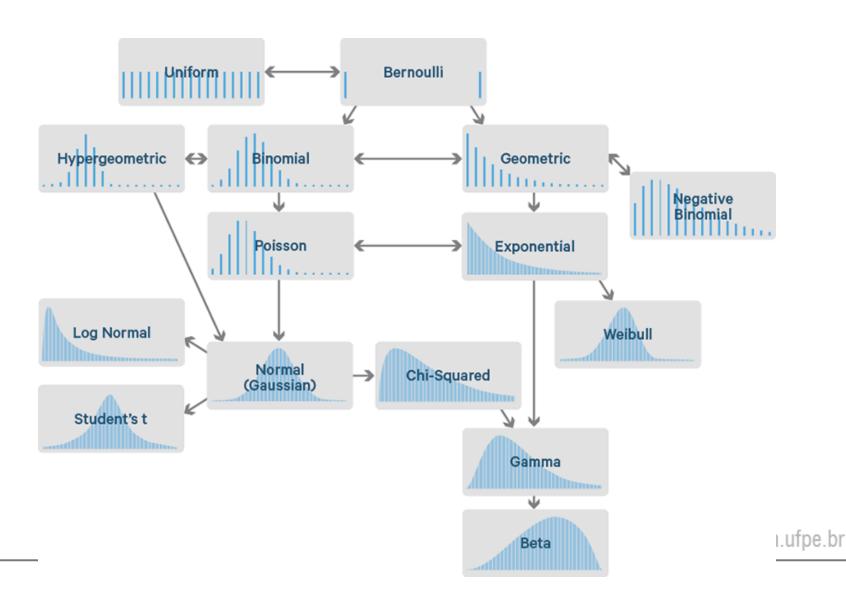
Luciano Barbosa







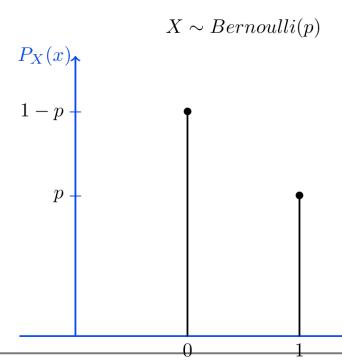
Distribuições de Probabilidade





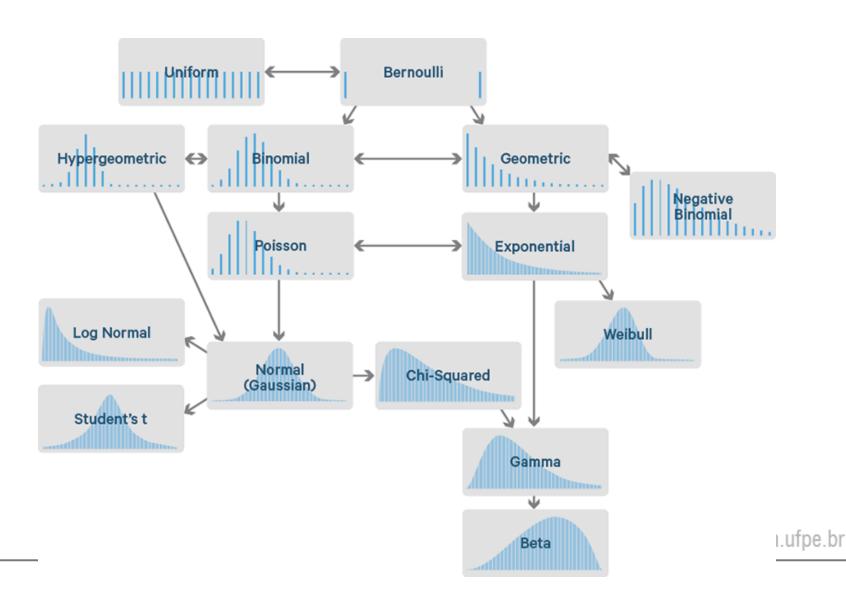
Bernoulli

- Valores discretos
- Dois valores possíves: 0 (falha) ou 1 (sucesso)
- Ex:
 - Lançamento de uma moeda
 - Passar num concurso





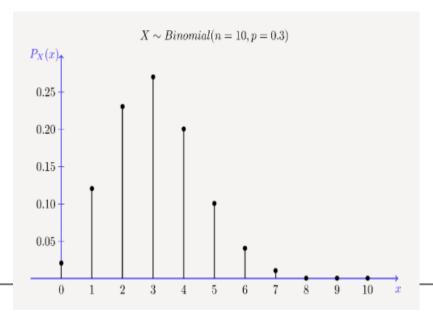
Distribuições de Probabilidade

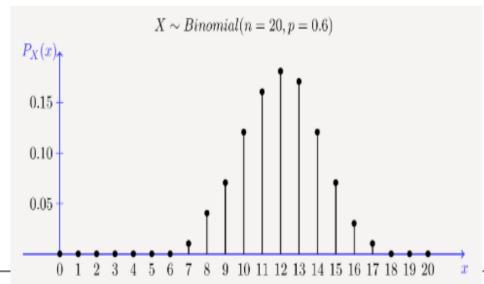




Binomial

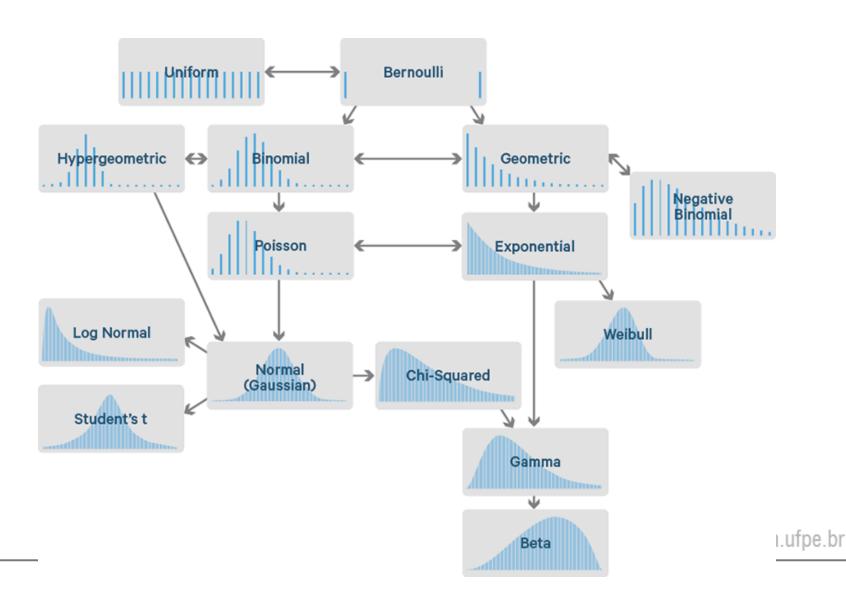
- Prob. de número de sucessos de n experimentos que seguem distribuição de Bernoulli com probabilidade p
- Ex.:
 - Prob. de número de vezes coroa aparece depois de n lançamentos de uma moeda
 - Número de bolas pretas retiradas de uma urna com bolas pretas e brancas







Distribuições de Probabilidade



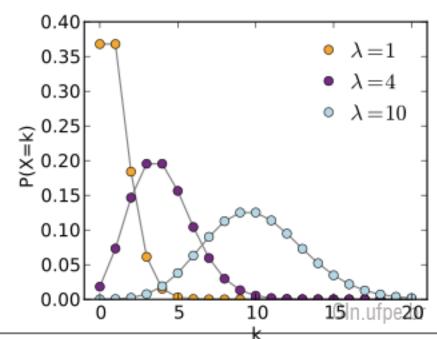


Poisson

- Prob. de um número de eventos (k) em um determinado tempo ou espaço a uma taxa média
- Ex: prob. de números de clientes que ligam pro SAC em um determinado período

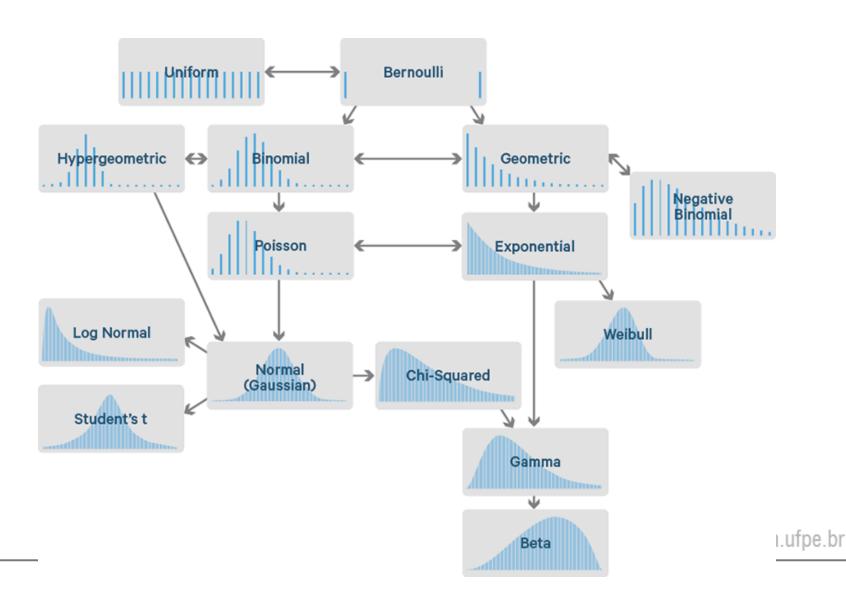
Cada segundo poderia ser bernoulli mas se houver milhões de

chamadas em 1 segundo?





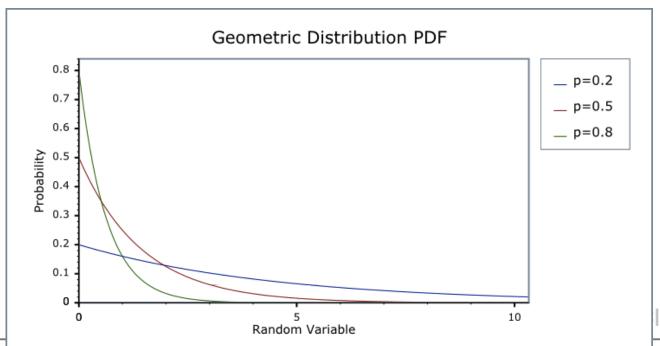
Distribuições de Probabilidade





Geométrica

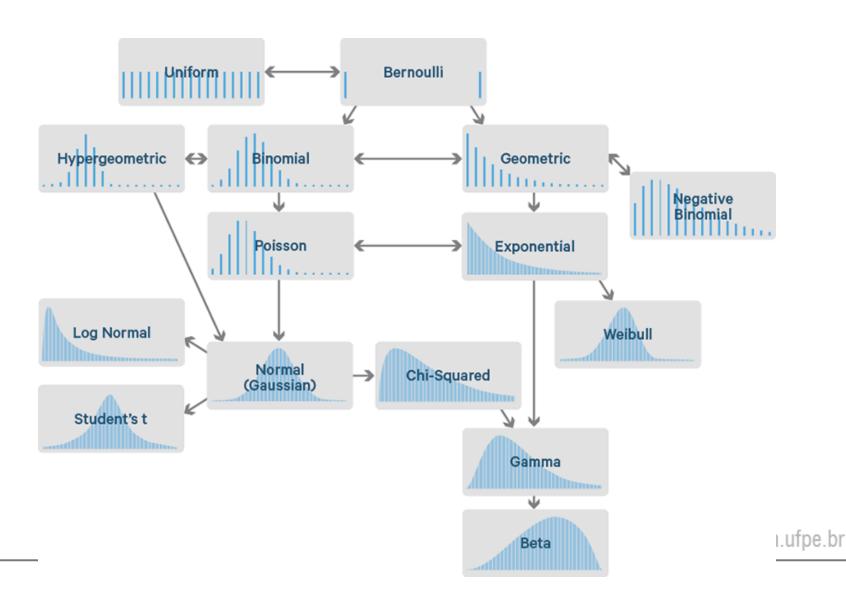
- Derivada da Bernoulli
- Prob. de observar k falhas até 1 sucesso de evento de probabilidade p
- Ex: Prob. de quantas vezes o lançamento de uma moeda vem coroa (falha) antes do primeiro cara



In.ufpe.br



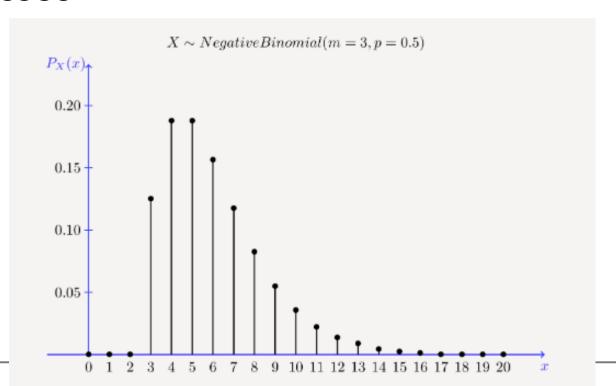
Distribuições de Probabilidade





Binomial Negativa ou Pascal

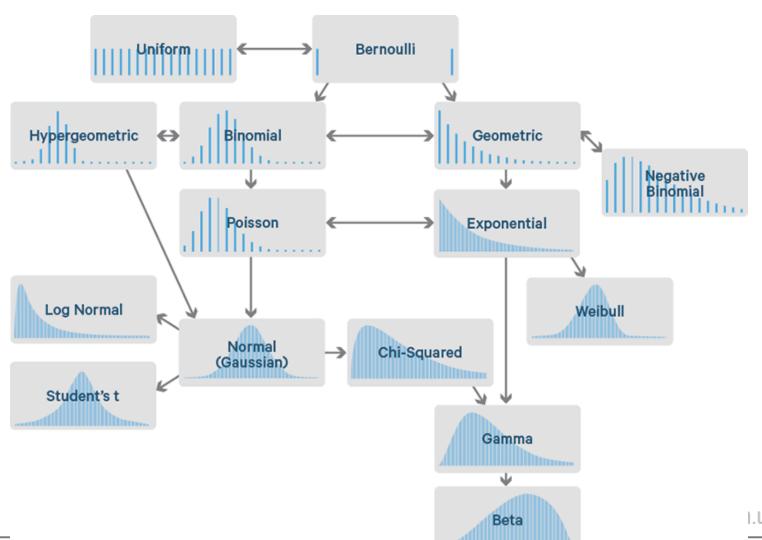
- Generalização da geométrica
- Prob. de observar k números de falhas até m sucessos



Cln.ufpe.br



Distribuições de Probabilidade

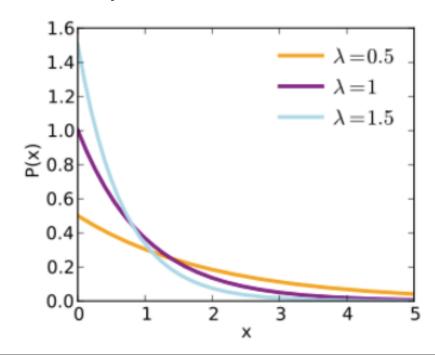


ı.ufpe.br



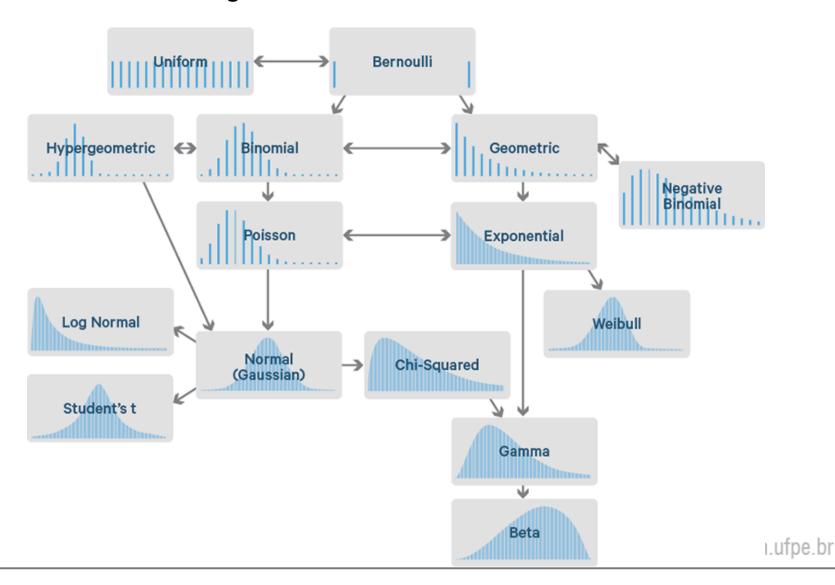
Exponencial

- Prob. de passar x tempo para o próximo sucesso
- Geométrica para valores contínuos



Ź

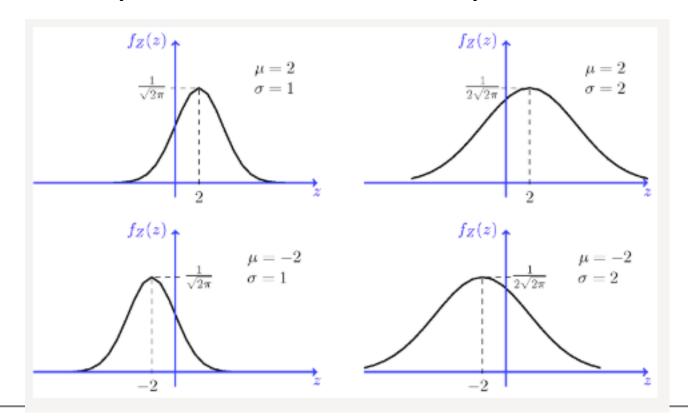
Distribuições de Probabilidade





Normal ou Gaussiana

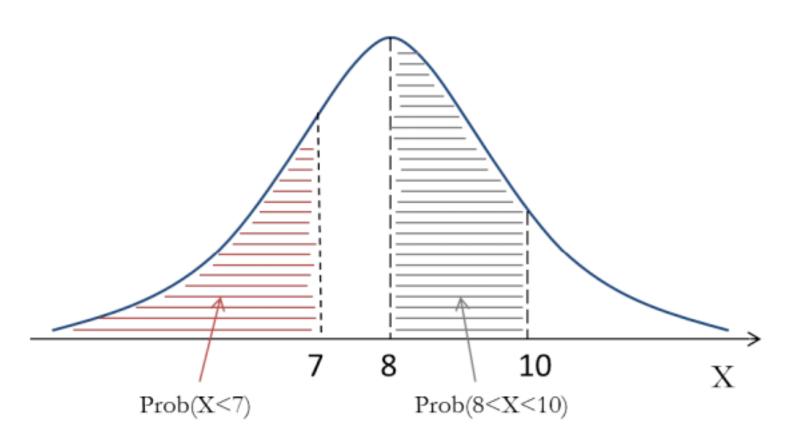
- Distribuição mais importante
- Definida pela média e desvio padrão



Cln.ufpe.br



Probabilidade de Intervalos





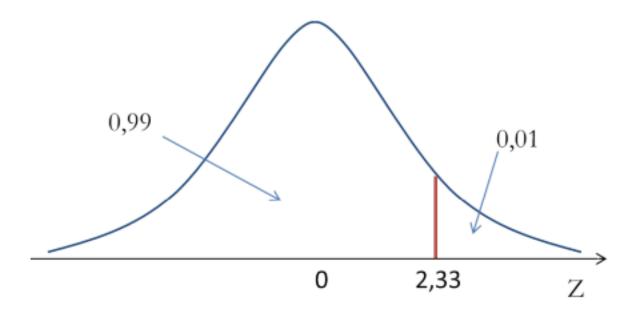
Normalizando para Gaussiana Padrão

- z: z-score $z = (X \mu) / \sigma$
- Número de desvio padrões com relação à média
- Valor 0: X é igual a média
- Valor 1: 1 desvio padrão maior que a média

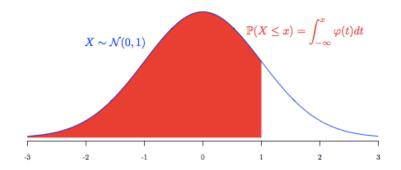


Normal ou Gaussiana Padrão

$$X \sim N(\mu, \sigma^2) \rightarrow \frac{X - \mu}{\sigma} \sim N(0, 1) = Z$$



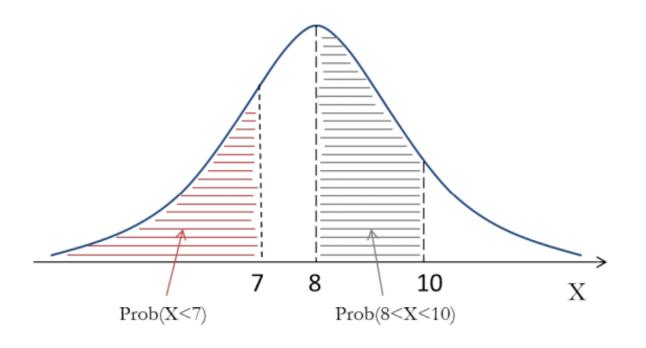




0.00 0.01 0.02 0 0.0 0.5000 0.5040 0.5080 0.5 0.1 0.5398 0.5438 0.5478 0.5 0.2 0.5793 0.5832 0.5871 0.5 0.3 0.6179 0.6217 0.6255 0.6 0.4 0.6554 0.6591 0.6628 0.6 0.5 0.6915 0.6950 0.6985 0.70	517 0.5557 510 0.5948 529 0.6331 564 0.6700 519 0.7054 557 0.7389	0.05 0.5199 0.5596 0.5987 0.6368 0.6736 0.7088 0.7422	0.06 0.5239 0.5636 0.6026 0.6406 0.6772 0.7123	0.07 0.5279 0.5675 0.6064 0.6443 0.6808 0.7157	0.08 0.5319 0.5714 0.6103 0.6480 0.6844 0.7190	0.09 0.5359 0.5753 0.6141 0.6517 0.6879
0.1 0.5398 0.5438 0.5478 0.55 0.2 0.5793 0.5832 0.5871 0.55 0.3 0.6179 0.6217 0.6255 0.65 0.4 0.6554 0.6591 0.6628 0.66	517 0.5557 510 0.5948 529 0.6331 564 0.6700 519 0.7054 557 0.7389	0.5596 0.5987 0.6368 0.6736 0.7088	0.5636 0.6026 0.6406 0.6772 0.7123	0.5675 0.6064 0.6443 0.6808	0.5714 0.6103 0.6480 0.6844	0.5753 0.6141 0.6517 0.6879
0.2 0.5793 0.5832 0.5871 0.59 0.3 0.6179 0.6217 0.6255 0.62 0.4 0.6554 0.6591 0.6628 0.66	010 0.5948 093 0.6331 064 0.6700 019 0.7054 057 0.7389	0.5987 0.6368 0.6736 0.7088	0.6026 0.6406 0.6772 0.7123	0.6064 0.6443 0.6808	0.6103 0.6480 0.6844	0.6141 0.6517 0.6879
0.3 0.6179 0.6217 0.6255 0.65 0.4 0.6554 0.6591 0.6628 0.66	293 0.6331 664 0.6700 019 0.7054 357 0.7389	0.6368 0.6736 0.7088	$0.6406 \\ 0.6772 \\ 0.7123$	0.6443 0.6808	$0.6480 \\ 0.6844$	$0.6517 \\ 0.6879$
0.4 0.6554 0.6591 0.6628 0.66	0.6700 019 0.7054 017 0.7389	$0.6736 \\ 0.7088$	$0.6772 \\ 0.7123$	0.6808	0.6844	0.6879
	019 0.7054 019 0.7389	0.7088	0.7123			
0.5 0.6915 0.6950 0.6985 0.70	357 0.7389			0.7157	0.7100	0 200 :
		0.7422	0 5454		0.7190	0.7224
0.6 0.7257 0.7291 0.7324 0.73	373 0 7704		0.7454	0.7486	0.7517	0.7549
0.7 0.7580 0.7611 0.7642 0.76	0.1104	0.7734	0.7764	0.7794	0.7823	0.7852
0.8 0.7881 0.7910 0.7939 0.79	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9 0.8159 0.8186 0.8212 0.83	238 0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0 0.8413 0.8438 0.8461 0.84	185 0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1 0.8643 0.8665 0.8686 0.8	708 0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2 0.8849 0.8869 0.8888 0.89	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3 0.9032 0.9049 0.9066 0.90	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4 0.9192 0.9207 0.9222 0.93	236 0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5 0.9332 0.9345 0.9357 0.93	370 0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6 0.9452 0.9463 0.9474 0.94	184 0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7 0.9554 0.9564 0.9573 0.98	682 0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8 0.9641 0.9649 0.9656 0.96	664 0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9 0.9713 0.9719 0.9726 0.9	732 0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0 0.9772 0.9778 0.9783 0.9	788 0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1 0.9821 0.9826 0.9830 0.98	334 0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2 0.9861 0.9864 0.9868 0.98	371 0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3 0.9893 0.9896 0.9898 0.99	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4 0.9918 0.9920 0.9922 0.99	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5 0.9938 0.9940 0.9941 0.99	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6 0.9953 0.9955 0.9956 0.99	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7 0.9965 0.9966 0.9967 0.99	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8 0.9974 0.9975 0.9976 0.99		0.9978	0.9979	0.9979	0.9980	0.9981
2.9 0.9981 0.9982 0.9982 0.99	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0 0.9987 0.9987 0.9987 0.99	988 0.9988	0.9989	0.9989	0.9989	0.9990	0.9990



Calculando Probabilidades



$$Prob(X < 7) = Prob(X - 8 < 7 - 8) = Prob(X - 8 < -1) =$$

$$= Prob(\frac{X - 8}{4} < -\frac{1}{4}) = Prob(\frac{X - 8}{4} < -0, 25)$$

$$Prob(X < 7) = Prob(Z < -0.25) = 1 - Prob(Z > 0.25)$$

= 1 - 0.5987 = 0.4013 = 40.13%

Cln.ufpe.br



Teste de Hipótese: Conceitos

- Aceita ou rejeita hipótese sobre uma população a partir de uma amostra de dados
 - Ex: Diferença de peso entre recém-nascidos de alta e baixa renda é siginificante?
- Hipóteses nula (não há diferença) e alternativa (há diferença)



Teste Bilateral

 O índice de homicídio em Pernambuco é diferente da média nacional de 50 por 100 mil habitantes?

• H0: $\mu = 50$

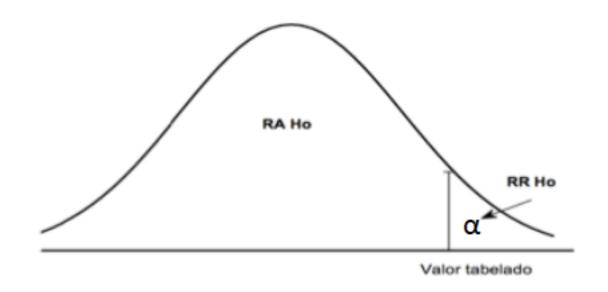
• H1: $\mu \neq 50$





Teste Unilateral

- O índice de homicío em Pernambuco é maior que a média nacional de 50 por 100 mil habitantes?
- H0: $\mu = 50$
- H1: $\mu > 50$





Teste Unilateral

- O índice de homicío em Pernambuco é menor que a média nacional de 50 por 100 mil habitantes?
- H0: $\mu = 50$
- H1: μ < 50





Nível de Significância

- Também chamado de valor crítico
- Probabilidade máxima para se rejeitar a hipótese nula
- Usalmente 1% ou 5%

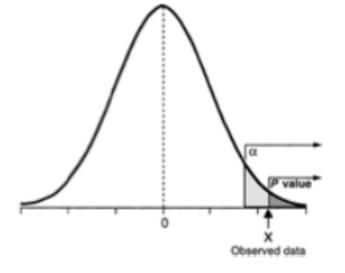




P-Value

Probabilidade da hipótese nula ser verdadeira

 Um valor pequeno (menor que valor crítico) indica evidência forte contra a hipótese nula (rejeitada)





Grupos Pariados vs Não-Pariados

- Pariados: mesmos indivíduos em diferentes situações
 - Ex: efeito de medicamento num mesmo grupo
- Não-pariados: indivíduos diferentes
 - Ex: efeito de medicamento em grupos diferentes



Testes Paramétricos vs Não-Paramétricos

- Paramétricos: assumem distribuição normal dos dados
- Não-paramétricos: não assumem uma distribuição a priori



l Tabela de Teste de Hipótese

	TYPE OF DATA					
GOAL	Measurement (with normal distribution)	Rank, Score, or Measurement (from non-normal distribution)	Binomial (two possible outcomes)			
Describe 1 group	Mean, SD Median, interquartile range		Proportion			
Compare 1 group to a hypothetical value One-sample t test		Wilcoxon test	Chi-square or Binomial test **			
Compare 2 unpaired groups	Unpaired <i>t</i> test	Mann-Whitney test	Fisher's test (chi-square for large samples)			
Compare 2 paired groups	Paired t test	Wilcoxon test	McNemar's test			
Compare 3 or more Unmatched groups One-way ANOVA		Kruskal-Wallis test	Chi-square test			
Compare 3 or more matched groups Repeated-measures ANOVA		Friedman test	Cochrane Q**			
Quantify association between 2 variables Pearson correlation		Spearman correlation	Contingency coefficients**			

Cln.ufpe.br



One-Sample t-Test

- Verificar se há diferença significativa entre a média de uma população e uma amostra
- Média da população conhecida mas desvio padrão não
- Etapas:
 - Definir hipótese nula e alternativa
 - Definir valor crítico
 - Comparar o resultado com o valor crítico



One-Sample t-Test: Exemplo

- Média de QI da população é 100
- Testar o efeito de uma nova medicação no QI
- Amostra de 30 pessoas tomaram medicamento:
 - Média de QI = 140
 - Desvio padrão = 20



One-Sample t-Test: Etapas

Definir hipótese nula e alternativa

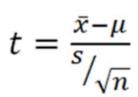
$$H_0$$
; $\mu = 100$
 H_1 ; $\mu \neq 100$

- Definir valor crítico: 0.05
- Comparar o resultado com o valor crítico



One-Sample t-Test: Etapas

Comparar o resultado com o valor crítico

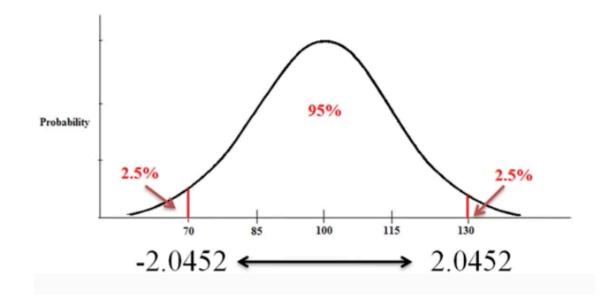


$$\bar{x} = 140$$

$$\mu = 100$$

$$s = 20$$

$$n = 30$$

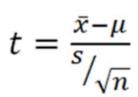


$$t = \frac{140 - 100}{20 / \sqrt{30}} = \frac{40}{3.65} = 10.96$$



One-Sample t-Test: Etapas

Comparar o resultado com o valor crítico

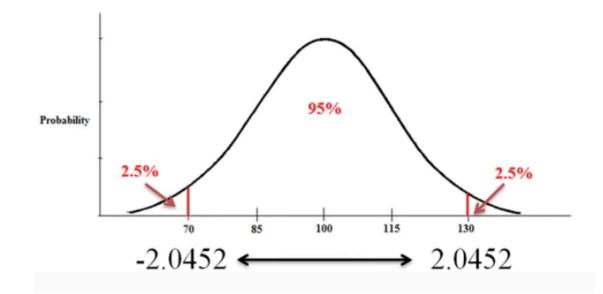


$$\bar{x} = 140$$

$$\mu = 100$$

$$s = 20$$

$$n = 30$$



$$t = \frac{140 - 100}{20 / \sqrt{30}} = \frac{40}{3.65} = 10.96$$

Hipótese nula rejeitada!



Comparar 2 Grupos Pareados: t-Test Pariado

- Hipótese nula: não há diferença entre a média das amostras
- Suposições
 - Diferença entre as amostras é gaussiana (ou próxima dela)
 - Não pode conter outliers
 - Mesma população



Comparar 2 Grupos Pareados: Wilcoxon signed-rank Test

- Hipótese nula: não há diferença entre as amostras
- Suposições
 - Não paramétrica: diferença não corresponde à gaussiana
 - Diferença segue uma distribuição simétrica
 - Mesma população



Comparar 2 Grupos Não-Pareados: t-Test Não-Pariado

- Hipótese nula: não há diferença entre a média das amostras
- Suposições
 - Observações de um grupo são independentes do outro grupo
 - Grupos seguem a normal
 - Variâncias dos dois grupos são iguais



Comparar 2 Grupos Não-Pareados: Mann-Whitney U test

- Hipótese nula: amostras vêm de populações com mesma distribuição
- Suposições
 - Não paramétrica: amostras não correspondem à gaussiana
 - Observações de um grupo são independentes do outro grupo



l Tabela de Teste de Hipótese

	TYPE OF DATA					
GOAL	Measurement (with normal distribution)	Rank, Score, or Measurement (from non-normal distribution)	Binomial (two possible outcomes)			
Describe 1 group	Mean, SD Median, interquartile range		Proportion			
Compare 1 group to a hypothetical value One-sample t test		Wilcoxon test	Chi-square or Binomial test **			
Compare 2 unpaired groups	Unpaired <i>t</i> test	Mann-Whitney test	Fisher's test (chi-square for large samples)			
Compare 2 paired groups	Paired t test	Wilcoxon test	McNemar's test			
Compare 3 or more Unmatched groups One-way ANOVA		Kruskal-Wallis test	Chi-square test			
Compare 3 or more matched groups Repeated-measures ANOVA		Friedman test	Cochrane Q**			
Quantify association between 2 variables Pearson correlation		Spearman correlation	Contingency coefficients**			

Cln.ufpe.br