

Pré-Processamento de Dados: Detecção de Outliers

Luciano Barbosa

Fontes de Erro

- Inserção dos dados
- Coleta dos dados

Tarefa Exploratória

- Ferramentas para limpeza
- Visualização dos dados
- Human in the loop


Tipos de Problemas nos Dados

- Dados faltantes
- Dados duplicados
- Dados irrelevantes
- Dados incorretos

Dados Incorretos (Outliers)

- Observação que não está próxima ao centro

Age(Years)
75
80
65
55
67
78
88
90
45
58
69
80
110




Métodos de Detecção Univariado

- Z-Score robusto
- Tukey

Centro and Dispersão

- Centro
 - Valor médio
 - Ex:
média,
mediana
- Dispersão
 - Desvio do centro
 - Ex:
variância,
desvio padrão



Z-Score Robusto

- Distribuição precisa ser simétrica
- Centro: Mediana
 - Metade dos valores são menores e metade são maiores
 - É influenciado pelas posições dos outliers mas não pelos seus valores

Z-Score Robusto

- Dispersão: Median absolute deviation
 - Mediana da distância da diferença de todos valores da mediana

$$MAD = \text{median} \left| x_i - \hat{x} \right|$$


Z-Score Robusto

$$M_i = \frac{0.6745 (x_i - \bar{x})}{MAD}$$


- Constante $b = 0.6745$: fator de escala que torna MAD um estimador não-enviesado do desvio padrão: $E(MAD) = 0.675 \sigma$
- $M_i > \text{limiar}$: indica outlier (ex., 3 ou 3.5)

Método de Tukey

- Distribuição precisa ser simétrica
- Baseado em quartis
- Outliers:
 - Valores menores que $Q1 - 1.5 * IQR$
 - Valores maiores que $Q3 + 1.5 * IQR$



Bivariado




- Solução: transformar a relação em univariada (ex.: razão de uma variável pela outra)

Multivariado: Elliptic Envelope

- Suposição: atributos seguem gaussiana

Outlier detection via Elliptic Envelope



Multivariado: Elliptic Envelope

- Suposição: atributos seguem gaussiana
- Utiliza distância Mahalanobis

T indicates a transposed matrix

$$D^2 = (x - \bar{x})^T S^{-1} (x - \bar{x})$$

Matrix of distances from mean Inverse of covariance matrix

Matrix of:
 $(x_1, x_2, \dots, x_n) - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)$

or


$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} - \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_n \end{bmatrix}$$

$$\begin{bmatrix} s_1^2 & \dots & \text{Cov}(s_n, s_1) \\ \vdots & \ddots & \vdots \\ \text{Cov}(s_1, s_n) & \dots & s_n^2 \end{bmatrix}$$

Matrix with diagonals =
 variance of samples 1 ... n
 and cells = covariance of
 samples (1,2) ... (1,n)


Por que não Distância Euclidiana?

$$\sqrt{(x_i - \bar{x})^2 + (y_i - \bar{y})^2 + \dots + (n_i - \bar{n})^2}$$





Limitação da Distância Euclidiana

- Covariância entre as variáveis




Covariância




Remover a Covariância


- Projetar os pontos nos Autovetores
- Rotacionar os pontos
- Novos eixos são os autovetores
- Reescalar os valores dos pontos em cada eixo pela raiz quadrada do auto-valor




Exemplo: Distância Mahalanobis




Exemplo: Distância Mahalanobis



Exemplo: Distância Mahalanobis



Exemplo: Distância Mahalanobis



Multivariado: Elliptic Envelope

- Suposição: atributos seguem gaussiana
- Utiliza distância Mahalanobis

T indicates a transposed matrix

$$D^2 = (x - \bar{x})^T S^{-1} (x - \bar{x})$$

Matrix of distances from mean Inverse of covariance matrix

Matrix of:
 $(x_1, x_2, \dots, x_n) - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)$

or

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} - \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_n \end{bmatrix}$$


$$\begin{bmatrix} s_1^2 & \dots & \text{Cov}(s_n, s_1) \\ \vdots & \ddots & \vdots \\ \text{Cov}(s_1, s_n) & \dots & s_n^2 \end{bmatrix}$$

Matrix with diagonals =
 variance of samples 1 ... n
 and cells = covariance of
 samples (1,2) ... (1,n)

Minimum Covariance Determinant


- Encontrar a matriz de covariância com mínimo volume dentro de % dos dados

CLASSICAL AND ROBUST TOLERANCE ELLIPSE (97.5%)



Detectando Outliers



- Computar a distância Mahalanobis para cada amostra
- Outliers: amostras com distância maior que um determinado valor crítico da distribuição chi-square



Isolation Forests

- Não-paramétrico
- Suposição: outliers são poucos e diferentes
- Passos:
 1. Seleciona aleatoriamente um feature
 2. Seleciona um valor aleatório dela entre o máximo e mínimo
 3. Repete passos 1 e 2 n vezes

Isolation Forests



Isolation Forests

- Fácil de isolar outliers: poucas condições necessárias para separar dos demais
- Score: profundidade média do ponto na árvore necessária para isolar o ponto
 - Perto de 1 indica outlier