



Interpretabilidade em Modelos de ML

Luciano Barbosa

Modelos Black Box



Viés em Modelos

	
DYLAN FUGETT	BERNARD PARKER
Prior Offense 1 attempted burglary	Prior Offense 1 resisting arrest without violence
Subsequent Offenses 3 drug possessions	Subsequent Offenses None
LOW RISK 3	HIGH RISK 10
<i>Fugett was rated low risk after being arrested with cocaine and marijuana. He was arrested three times on drug charges after that.</i>	

Viés em Modelos

Bloomberg Businessweek

Apple Card's Gender-Bias Claims Look Familiar to Old-School Banks



Updated on November 12, 2019, 4:23 AM

 MIT News

Study finds gender and skin-type bias in commercial AI systems



Feb 12, 2018

 NEWS

Tay: Microsoft issues apology over racist chatbot fiasco



Sep 22, 2017

 Missouri SST News and Research

After Uber, Tesla incidents, can artificial intelligence be trusted?



Apr 10, 2018

Guilty! AI is Found to Perpetuate Biases in Jailing



1 day ago


Para que Interpretabilidade?

- Verificar se o modelo funciona como o esperado

*“Autonomous car crashes,
because it wrongly recognizes ...”*




*“AI medical diagnosis system
misclassifies patient’s disease ...”*



Para que Interpretabilidade?

- Verificar problemas e melhorar modelos



Para que Interpretabilidade?

- Verificar problemas e melhorar modelos



Top label: **"clog"**

Why did the network label this image as **"clog"**?

Para que Interpretabilidade?


- Aprender novos insights

"It's not a human move. I've never seen a human play this move." (Fan Hui)




Para que Interpretabilidade?

- Confirmed with legislation



Acurácia X Explicabilidade



Estratégias


- Explicação dado um modelo de ML
 - Predição individual
 - Predição global
- Construção de um modelo interpretável
 - Decision trees, regressão linear etc

SHAP: SHapley Additive exPlanations

- Predição individual
- Utiliza teoria dos jogos
- Jogo: saída do modelo
- Jogadores: features do modelo
- Contribuição de cada feature (jogador) para o jogo (predição)


SHAP: Exemplo

- Cada possível coalizão de jogadores determina a importância de um jogador
- Predizer renda a partir de idade, sexo e emprego




SHAP: Exemplo

- Treina um modelo para cada coalizão (mesmo conjunto de treinamento e hiper-parâmetros)




SHAP: Exemplo

- Contribuição marginal (aresta): diferença entre previsões de dois nós conectados é o efeito da feature adicional




Contribuição da idade




$$\begin{aligned}
 SHAP_{Age}(x_0) = & w_1 \times MC_{Age, \{Age\}}(x_0) + \\
 & w_2 \times MC_{Age, \{Age, Gender\}}(x_0) + \\
 & w_3 \times MC_{Age, \{Age, Job\}}(x_0) + \\
 & w_4 \times MC_{Age, \{Age, Gender, Job\}}(x_0)
 \end{aligned}$$

Pesos

- Soma dos pesos para cada linha tem que ser igual: $w_1 = w_2 + w_3 = w_4$
- Os pesos na mesma linha são iguais: $w_1 = 1/3$; $w_2 = 1/6$; $w_3 = 1/6$; $w_4 = 1/3$



Resultado para Idade



$$\begin{aligned} SHAP_{Age}(x_0) &= \frac{1}{3} \times (-10k\$) + \frac{1}{6} \times (-9k\$) + \frac{1}{6} \times (-15k\$) + \frac{1}{3} \times (-12k\$) \\ &= -11.33k\$ \end{aligned}$$

Resultado Final

$$\text{SHAP_Age}(x_0) = -11.33\text{k \$}$$

$$\text{SHAP_Gender}(x_0) = -2.33\text{k \$}$$

$$\text{SHAP_Job}(x_0) = +46.66\text{k \$}$$

